



Pipeline de données temps réel pour Nvidia et dashboard analytique



Architecture événementielle • Processing de flux • Visualisation interactive

Auteurs

Kaddouri Oussama

Oussama Laghchim

Anouar Tayi

Ahmed QAIS



ENSIAS

Encadrant :

M. Yasser El MADANI ALAMI





Plan

Architecture complète du pipeline de données
temps réel dédié à Nvidia

- 1 Contexte et Problématique
- 2 Architecture Globale
- 3 Choix Technologiques
- 4 Sources de Données
- 5 Ingestion & Processing
- 6 Dashboard Streamlit
- 7 Résultats et Extension
- 8 Conclusion

Contexte Général



NVDA - Nvidia Corporation

Titre fortement suivi

- ✓ Volatilité attrayante pour les investisseurs
- ✓ Communautés en ligne actives et influentes



Objectif du projet

Architecture temps réel multi-sources

- Collecter données de marché et sociales
- Traiter en continu (quasi temps réel)
- Visualiser via dashboard interactif






Comment rendre disponibles des données hétérogènes de manière homogène et quasi temps réel ?




Données de marché

Séries de prix OHLCV
Historiques et quotidiens




Signaux sociaux

Posts Reddit, messages StockTwits
Actualités Yahoo News



Quasi temps réel

Disponibilité continue pour
l'analyse et la décision



Unification des formats

Normalisation et
homogénéisation des flux



Défi technique : Rendre ces signaux exploitables par les analystes et investisseurs

Objectifs et Périmètre

Objectifs Principaux

- 1 Architecture en temps réel**
Ingestion multi-sources avec Kafka
- 2 Stream processing robuste**
Spark Structured Streaming
- 3 Stockage persistant**
MongoDB Atlas avec data model stable
- 4 Dashboard interactif**
Visualisation avec Streamlit

Périmètre du Projet

Données autour de NVDA



Prix OHLCV



Posts Reddit



StockTwits



Yahoo News



En dehors du périmètre

Prédiction automatique et modèles de trading non inclus dans cette version

Architecture Globale

Pipeline en 4 couches




Scripts Python

Scrapers & Producers (Yahoo, Reddit, StockTwits, News)




Bus d'événements

Topics dédiés par source (topic_stock_prices, topic_reddit_posts...)




Stream Processing

Structured Streaming (parsing, validation, enrichment)



Stockage Persistant

Collections MongoDB (stock_prices, nvidia_reddit_posts...)



Dashboard Analytique

KPI, visualisations techniques, activité sociale

Choix Technologiques



Apache Kafka

- ✓ Ingestion et transport des événements
- ✓ Découplage producteurs/consommateurs
- ✓ Architecture extensible via topics



Spark Structured

- ✓ Stream processing en micro-batch
- ✓ Schema validation et timestamp handling
- ✓ Fault tolerance via checkpointing



MongoDB Atlas

- ✓ Stockage persistant des collections
- ✓ Data model simple et exploitable
- ✓ Couche analytique pour le dashboard



Streamlit

- ✓ Dashboard interactif et rapide
- ✓ Visualisations techniques (KPI, charts)
- ✓ Interface sans pile front-end complexe

Sources de Données



Yahoo Finance

- Prix historiques OHLCV
- Volume de trading
- Dividends & Stock Splits



Reddit

- Posts relatifs à Nvidia
- Titre, auteur, score
- Date de publication



StockTwits

- Messages financiers NVDA
- User, sentiment, likes
- Date et contenu du message



Yahoo News

- Actualités financières
- Publisher, titre, lien
- Date de publication

Ingestion et Transport (Kafka)

Bus d'Événements

✓ Découplage
producteurs/consommateurs

✓ Publication indépendante par
source

 **topic_stock_prices**

Prix OHLCV

 **topic_reddit_posts**

Posts Reddit

 **topic_stocktwits_posts**

Messages StockTwits

 **topic_yahoo_news**

Actualités Yahoo

 **Avantages clés**

• Tolérance aux redémarrages

• Architecture extensible

• Scalable

Stream Processing (Spark)

Apache Spark Structured Streaming



Micro-batch Model

Exécution par intervalles d'offsets Kafka



Schema Validation

StructType explicite pour chaque topic



Timestamp Handling

Conversion dates → unified timestamp



Fault Tolerance

CheckpointLocation par collection

Associations Topic » Collection

- topic_stock_prices → stock_prices
- topic_reddit_posts → nvidia_reddit_posts
- topic_stocktwits_posts → nvidia_stocktwits_posts
- topic_yahoo_news → nvidia_yahoo_news

Stockage (MongoDB Atlas)

Base de données : NvidiaStockData

 **stock_prices**

Prix OHLCV, Volume

 **nvidia_reddit_posts**

Posts Reddit NVDA

 **nvidia_stocktwits_posts**

Messages StockTwits

 **nvidia_yahoo_news**

Actualités Yahoo

Indexation recommandée

Index sur **timestamp** pour accélérer les requêtes dashboard



Schemas stables



Data model simple



Requêtes analytiques

Interface Analytique Interactive



Tendances Prix

Close over time
Candlesticks
Moving averages



Volume/Volatilité

Volume bars
Volatility index
High/Low



Social Streams

Reddit feed
StockTwits feed
Agrégations

KPI Clés

Average Close

\$XXX

Average Volume

XXXM

All-Time High/Low

XXX/XXX

-  Filtres temporels
-  Visualisations techniques
-  Activité sociale

Orchestration

Infrastructure Docker Compose

- ✓ Zookeeper
- ✓ Apache Kafka
- ✓ Spark Streaming
- ✓ Services applicatifs

Mode Opérateur

1

Démarrer l'infrastructure

`docker-compose up -d`

Orchestre Zookeeper et Kafka

2

Démarrer les producers

`start_producers.bat` / scripts Python

Alimentation continue des topics Kafka

3

Démarrer processing & dashboard

Spark processor + Streamlit

Traitement en flux et visualisation



Configuration simple et reproductible

Dashboard d'Exploration Analytique



KPI

- Prix clôture moyen
- Volume moyen
- Plus haut/bas historiques



Tendances

- Chandeliers OHLC
- Moyennes mobiles
- Volatilité High-Low



Vue Synthétique

Analyse technique et contextuelle de Nvidia

Analyse Technique

Prix & Volume

Contexte Social

Sentiment

Prise de Décision

Indicateurs Clés

Résultats et Indicateurs

Dashboard d'Exploration Analytique


10. 📌 Indicateurs clés (KPI)

Prix de clôture moyen	Volume moyen	Plus haut historique	Plus bas historique
\$156.30	216,414,487	\$212.18	\$86.60

 Tendances & Prix  Volume & Volatilité  Analyse Technique  Statistiques

1. 📈 Courbe du prix de clôture

Évolution du prix de clôture



4. 🕯️ Bougies japonaises (Candlestick)

Chandelier japonais (OHLC)



Extension – Séries Temporelles et Prédiction

Module Experimental de Forecasting



Modèles Comparés



Prophet (tendances & saisonnalité)



XGBoost (régression avec lags)

Prophet

1.17%

MAPE

3.25

RMSE

XGBoost

1.10%

MAPE

2.51

RMSE

Ensemble

0.98%

MAPE

2.37

RMSE



Validation : 14 derniers jours



Forecast : 3 prochains jours



Ensemble le plus performant

Extension – Séries Temporelles et Prédiction

Analyse fondamentale

Sentiment_discord

Mesure le consensus ou la division des investisseurs.

fear_index

Indique une vente de panique (Panic Selling).

product_hype_score

Indique si l'attention est focalisée sur les fondamentaux technologiques.

viral_sentiment

L'opinion de la "Smart Money" ou des influenceurs. Élimine le bruit des petits comptes peu suivis.

post_volume


Nombre brut de posts pertinents détectés ce jour-là.

attention_acceleration

Variation en pourcentage du volume de posts par rapport à la moyenne des 7 derniers jours (Moyenne Mobile).


Extension - Séries Temporelles et Prédiction

Creation du analyste financier




Extension – Séries Temporelles et Prédiction

demo du analyste financier



Extension – Séries Temporelles et Prédiction

demo du analyste financier



Validation et Évaluation



Validation End-to-End

- Producers publient dans Kafka
- Spark consomme et écrit dans MongoDB
- Dashboard affiche les KPI/charts



Qualité des Données

- ✓ Schema validation
- ✓ Temporal consistency
- ✓ Duplicate handling

Observations de Fonctionnement



Robustesse

Système robuste aux variations de débit des sources sociales

Découplage

MongoDB sert de couche tampon analytique pour le dashboard

Conclusion

Pipeline temps réel complet pour Nvidia



Ingestion Multi-Sources

- Yahoo Finance
- Reddit
- StockTwits
- Yahoo News



Architecture Moderne

- Apache Kafka
- Spark Streaming
- MongoDB Atlas
- Streamlit Dashboard



Analyse Complexe

- Technique (prix/volume)
- Contextuelle (sentiment)
- Prédiction (Prophet/XGBoost)
- Visualisation interactive



Base Solide pour Extensions Futures

Architecture évolutive prête pour intégration de l'analyse de sentiment avancée, alertes en temps réel et scalabilité accrue

Limites Actuelles

-  **Contraintes d'API**
Limitations des taux de scraping des sources
-  **Dérive des schémas**
Évolution potentielle des formats de données
-  **Sentiment rudimentaire**
Analyse de sentiment basique nécessitant amélioration

Pistes d'Amélioration

-  **Classification du sentiment**
Modèles pré-entraînés pour analyse avancée
-  **Enrichissements de features**
Événements macro, résultats financiers
-  **Alertes en temps réel**
Notifications automatiques pour événements majeurs
-  **Intégration forecasting**
Intégration complète du module de prévision
-  **Scalability**
Kafka partitioning, Spark tuning, tests d'intégration



Merci pour votre attention

Pipeline de données temps réel pour Nvidia